

Relatório Técnico: HealthSearch

Motor de Busca Híbrido (BM25 + Semântico)

Aluno: Gustavo Henrique de Lucena Paiva

Instituição: UNIPÊ — Centro Universitário de João Pessoa

Disciplina: Tendências em Ciência da Computação

Professor: Me. Ricardo Roberto de Lima

1. Como o Sistema Funciona (Arquitetura)

O HealthSearch foi construído em Python (Streamlit) com um pipeline direto para resolver os pontos cegos das buscas médicas comuns. Ele opera em 4 etapas práticas:

- Busca Léxica (BM25): Usa o algoritmo Okapi BM25 para encontrar palavras-chave e códigos exatos. A interface permite ajustar a saturação (k1) e a normalização (b) dinamicamente.
- Busca Semântica (FAISS): Usa a biblioteca sentence-transformers para gerar embeddings e o FAISS para buscar por contexto (similaridade de cosseno), resgatando sinônimos que a busca exata ignora.
- Fusão Híbrida (RRF): Junta os resultados do BM25 e do FAISS usando o cálculo de Reciprocal Rank Fusion (K=60). Isso equilibra o ranking final de forma justa, sem precisar normalizar os scores absolutos.
- Re-Ranking: Aplica um modelo Cross-Encoder sobre os top-candidatos do RRF para dar a nota final de relevância com a máxima precisão possível.

2. Testes na Prática (Análise de Ranks)

Ao testar o sistema, a vantagem da busca híbrida ficou muito clara em dois cenários complementares:

- Cenário 1 (Códigos Exatos): Buscando por "CÓD-ECG-12D", o BM25 cravou o documento certo no topo. O modelo semântico se perdeu no contexto genérico de cardiologia e jogou o documento para baixo.
- Cenário 2 (Sinônimos): Buscando por "ataque cardíaco", o BM25 zerou, pois o texto técnico usava o termo "infarto agudo do miocárdio". O modelo semântico, por entender o contexto, recuperou a diretriz perfeitamente.

Conclusão: O algoritmo de fusão RRF uniu o melhor dos dois mundos. Ele colocou o documento ideal no topo em ambos os cenários de teste, provando que a abordagem híbrida resolve as falhas dos modelos isolados.

3. Referências Técnicas e Uso de IA

O sistema roda utilizando os seguintes modelos abertos de inteligência artificial por baixo dos panos:

- Embeddings Vetoriais: Modelo all-MiniLM-L6-v2 (responsável pela busca semântica via FAISS).
- Re-Ranking: Modelo ms-marco-MiniLM-L-6-v2 (responsável pelo bônus de precisão final).

Uso de IA: Foi utilizado o LLM Gemini como meu "co-piloto". Ele me auxiliou a criar a estrutura visual (boilerplate) da interface no Streamlit, gerenciar a importação das bibliotecas, explicar o funcionamento do código, como testar a aplicação e revisar o texto deste relatório.